




信息与软件工程学院

编译技术

主讲教师： 陈安龙

上节知识回顾




第2章 词法分析器

- 词法分析器简介
- 词法分析器的实现方法
- 正则表达式
- 状态自动机NFA、DFA
- Thompson构造算法
- DFA的优化：Hopcroft算法
- 简单词法分析器示例

1. 词法分析是什么？

- 词法分析（Lexical Analysis）的工作是读入源代码的字符流，将其拆分成有意义的词法单元（Token）序列，同时丢弃空白字符、注释等对编译无用的部分。
- 是编译器中唯一直接接触源代码文本的阶段。输入是字符串，输出是Token流。



主要任务

- ① 识别词素 (Lexeme) : 从字符流中识别出单词、数字、符号等。
- ② 分类与编码: 将每个词素归类为某种Token类型, 并拥有内部编码。
- ③ 去除无关内容: 跳过空格、换行、制表符、注释。
- ④ 记录位置信息: 保存行号、列号, 便于报错和调试。
- ⑤ 发现并报告非法字符: 如`@`、`#`等不合法输入, 给出错误提示。

词法分析中三个核心概念

- ① 词素 (Lexeme)
- ② 词法单元 (Token)
- ③ 模式 (Pattern)

词素 (Lexeme)

- 词素是源代码中实际存在的一段字符序列，它是符合某个模式的、能够被识别为某个词法单元的具体实例。
- 词素是具体的：它存在于源程序代码中，由字符组成。
- 词素是连续的：它在源文件中是连续的字符块，不能有间断（除非空白字符本身不算，且会被跳过，但词素内部一般不含分隔符）。
- 词素依赖于模式：没有模式，就无法从字符流中划分出词素边界。
- 例如：假如有程序代码，`count = 12;`
 - ① `count` 是一个词素，它匹配标识符模式。
 - ② `=` 是一个词素，匹配赋值运算符模式。
 - ③ `12` 是一个词素，匹配整数常量模式。
 - ④ `;` 是一个词素，匹配分号模式。
- 注意：这里的空格不算词素，因为词法分析器会忽略空白。

词法单元 (Token)

- 是词法分析器的输出，它是一个内部数据结构，通常被表示为一个二元组：

Token = <词法单元类型, 属性值>

- 其中：

① **词法单元类型**：一个抽象符号，表示词素的类别，例如：**ID、INT_CONST、KEYWORD、OPERATOR、DELIMITER**等。

② **属性值**：对词法单元类型的**补充信息**，用于区分**同一类型下的不同词素**。例如**标识符的名字、常数的数值、在符号表中的位置**等。

词法单元为什么需要属性？

- 词法分析器在后续语法分析中并不关心词素本身的样子，而关心它属于哪一类以及某些具体信息。
- 例如：
 - ① 如果词素是pi，Token类型为ID，属性值可能是指向符号表中“pi”条目的指针。
 - ② 如果词素是3.14，Token类型为FLOAT_CONST，属性值是浮点数3.14。

以下是一个简单的C语言代码片段：

```
int main() {  
    int a = 10;  
    float b = 3.14;  
    printf("Sum: %f\n", a + b);  
    return 0;  
}
```

识别词法单元：

关键字：int、float、return

标识符：main、a、b、printf

运算符：=、+

分界符：<、>、(、)、;、,

整数常量：10

浮点数常量：3.14

字符串常量："Sum: %f\n"

构建标记(token)序列：

```
<int, > <id,main> <(, > <), > <{, >  
<int, > <id,a> <assign_op,=> <number,10>  
<float, > <id,b> <assign,=> <number,3.14>  
<id,printf> <(, > <string,"Sum: %f\n">  
<id,a> <op,+> <id,b> <), > <;, >  
<return, > <number,0> <;, >  
<}, >
```

注意：标记符的第1部分是词法单元名或类别，第2部分是词法单元的属性值，也可以没有属性，或者是指向符号表中该词法单元的指针。

在某些编译器中，为了方便实现，将词法单元的单词按类别进行编码，在标记序列中记录类别编码，属性中记录指向符号表记录的指针。每个关键字、分界符和运算符单独编码，对应的属性值为词法单元符号本身，常数对应属性值为常数值本身。

类别	单词	种别码	类别	单词	种别码	类别	单词	种别码
关键字	program	1	关键字	write	18	标识符	id	34
	var	2		true	19			
	integer	3		false	20			
	bool	4	运算符	not	21	常数	整常数	35
	real	5		and	22		实常数	36
	char	6		or	23		字符常数	37
	const	7		+	24		布尔常数	38
	begin	8		-	25	分界符	=	39
	if	9		*	26		;	40
	then	10		/	27		,	41
	else	11		<	28		'	42
	while	12		>	29		/*	43
	do	13		<=	30		*/	44
	for	14		>=	31		:	45
	to	15		==	32		(	46
	end	16		<>	33		)	47
	read	17					.	48

■ 例如有程序语句：


```
if i>j then  
    i=0  
else j=1
```

请注意：具体实现方式
取决编译器设计者的整
体考虑。

if	<9, if >
i	<34, 符号表记录地址>
>	<29, > >
j	<34, 符号表记录地址>
then	<10, then >
i	<34, 符号表记录地址>
=	<39, = >
0	<35, 0 >
else	<11, else >
j	<34, 符号表记录地址>
=	<39, = >
1	<35, 1 >

具体编译器采用的token结构有所不同，右边面是llvm/clang经词法分析器输出的token流。

```
int min(int a, int b) {  
    if (a<b)  
        return a;  
    else  
        return b;  
}
```



```
D:\>clang -cc1 -dump-tokens test.c  
int 'int' [StartOfLine] Loc=<test.c:1:1>  
identifier 'min' [LeadingSpace] Loc=<test.c:1:5>  
l_paren '(' Loc=<test.c:1:8>  
int 'int' Loc=<test.c:1:9>  
identifier 'a' [LeadingSpace] Loc=<test.c:1:13>  
comma ',' Loc=<test.c:1:14>  
int 'int' [LeadingSpace] Loc=<test.c:1:16>  
identifier 'b' [LeadingSpace] Loc=<test.c:1:20>  
r_paren ')' Loc=<test.c:1:21>  
l_brace '{' [LeadingSpace] Loc=<test.c:1:23>  
if 'if' [StartOfLine] [LeadingSpace] Loc=<test.c:2:5>  
l_paren '(' [LeadingSpace] Loc=<test.c:2:8>  
identifier 'a' Loc=<test.c:2:9>  
less '<' Loc=<test.c:2:10>  
identifier 'b' Loc=<test.c:2:11>  
r_paren ')' Loc=<test.c:2:12>  
return 'return' [StartOfLine] [LeadingSpace] Loc=<test.c:3:9>  
identifier 'a' [LeadingSpace] Loc=<test.c:3:16>  
semi ';' Loc=<test.c:3:17>  
else 'else' [StartOfLine] [LeadingSpace] Loc=<test.c:4:5>  
return 'return' [StartOfLine] [LeadingSpace] Loc=<test.c:5:9>  
identifier 'b' [LeadingSpace] Loc=<test.c:5:16>  
semi ';' Loc=<test.c:5:17>  
r_brace '}' [StartOfLine] Loc=<test.c:6:1>  
eof '' Loc=<test.c:6:2>  
  
D:\>
```

模式 (Pattern)

- 模式是词法分析器中用来描述一类词法单元可能具有的字符串形式的规则。它决定了什么样的字符序列是合法的。形式模式通常用以下几种形式表示：

① 正则表达式：最常见的形式，例如：

a) 标识符：`[a-zA-Z_][a-zA-Z0-9_]*`

b) 整数常量：`[0-9]+`

c) 浮点数：`[0-9]+\.[0-9]+`

模式 (Pattern)

- ② 有穷自动机：词法分析器在实现时常常将正则表达式转化为确定的有穷自动机 (DFA)，通过状态转移来识别词素。
- ③ 文字描述：有些模式在教材中也会用自然语言描述，比如“所有以字母开头的字母数字串”，但这只是辅助说明，真正在编译器中执行的是正则表达式或有穷自动机。

模式（Pattern）的关键特征

- 模式是抽象的，它不针对某一个具体的字符串，而是针对一类字符串。
- 一个模式对应一种词法单元类型，例如：
 - ① 关键字模式： `if|else|while|...` 对应 **KEYWORD** 类型
 - ② 运算符模式： `+|-|*|/` 对应 **OPERATOR** 类型
 - ③ 标识符模式： `[a-zA-Z][a-zA-Z_]*` 对应 **ID** 类型，表示标识符以字母开始，后面接0个或多个字母或下划线。
 - ④ 模式之间可能相互重叠，例如关键字 `if` 同时也符合标识符模式，此时词法分析器需要通过优先级规则来解决冲突（通常关键字优先）。

正则表达式

- 正则表达式是一种用于描述字符串模式的形式语言，它可以精确地匹配文本中的特定模式。正则表达式由普通字符（如字母、数字）和特殊字符（如元字符）组成，可以用来进行字符串匹配、查找、替换等操作。在编译器中，正则表达式通常用于词法分析阶段，用于定义词法单元（tokens）的模式。
- 正则表达式的准确定义指的是可以通过有限步骤确定性地判断一个字符串是否符合该正则表达式的模式。换句话说，正则表达式的匹配过程是可预测且有限的，不会出现歧义或无限循环的情况。

正则表达式的归纳描述

- ① ε 是表示空字符的正则表达式, $L(\varepsilon) = \{\varepsilon\}$ 表示只含空串的语言;
- ② 如果 a 是集 Σ 上的一个符号, 那么 a 是正则表达式, 并且 $L(a) = \{a\}$ 表示仅含有字符串 a 的语言;
- ③ 假设 r 和 s 都是正则表达式, 分别表示的语言为 $L(r)$ 和 $L(s)$, 那么
 - (a) $(r) | (s)$ 是一个正则表达式, 表示语言 $L(r) \cup L(s)$
 - (b) $(r)(s)$ 是一个正则表达式, 表示语言 $L(r) L(s)$
 - (c) $(r)^*$ 是一个正则表达式, 表示语言 $(L(r))^*$, $*$ 表示由 0 个或多个;
 - (d) $(r)^+$ 是一个正则表达式, 表示语言 $L(r)^+$

有时可以括号, $((a)(b)^*) | (c)$ 可以简写为 $ab^* | c$

正则表达式的例子 字母表 $\Sigma = \{a, b\}$

- 正则表达式 表示的字符串的集合(或者语言)

$a \mid b$ $\{a, b\}$

$(a \mid b)(a \mid b)$ $\{aa, ab, ba, bb\}$

$aa \mid ab \mid ba \mid bb$ $\{aa, ab, ba, bb\}$

a^* 由0个或多个 a 构成的所有字符串集合

$(a \mid b)^*$ 由任意个 a 或 b 构成的字符串集合

$a \mid a^*b$

- 复杂的例子

$(00 \mid 11 \mid ((01 \mid 10)(00 \mid 11)^*(01 \mid 10)))^*$

偶数个0和偶数个1组成的01字符串

正则表达式的代数性质

定律	描述
$r \mid s = s \mid r$	$\mid$ 是可交换的
$r \mid (s \mid t) = (r \mid s) \mid t$	$\mid$ 是可结合的
$(r \mid s) t = r (s t)$	“连接” 是可结合的
$r (s \mid t) = r s \mid r t$ $(s \mid t) r = s r \mid t r$	“连接” 是可分配的
$\varepsilon r = r$ $r \varepsilon = r$	ε 是 “连接” 的单位元
$r^* = (r \mid \varepsilon)^*$	$*$ 和 ε 之间的关系
$r^{**} = r^*$	$*$ 的幂等性

$$(rs)^* \neq r^*s^*$$
$$(r|s)^* \neq r^*|s^*$$

正则表达式的定义式

为了让正则表达式的表示简洁，可以对正则表达式取一个名字。

$$d_1 \rightarrow r_1$$

$$d_2 \rightarrow r_2$$

...

$$d_n \rightarrow r_n$$

每个 d_i 就是正则表达式的名字,并且互不相同 $d_i \notin \Sigma$

每个 r_i 都是 $\Sigma \cup \{d_1, d_2, \dots, d_{i-1}\}$ 上的正则式

正则定义的例子1

C语言的标识符集合

$letter \rightarrow A \mid B \mid \dots \mid Z \mid a \mid b \mid \dots \mid z \mid _$

$digit \rightarrow 0 \mid 1 \mid \dots \mid 9$

$id \rightarrow letter (letter \mid digit)^*$

如果代入，则有C语言标识符的正则表达式为

$(A \mid \dots \mid Z \mid a \mid \dots \mid z \mid _)(A \mid \dots \mid Z \mid a \mid \dots \mid z \mid _ \mid 0 \mid 1 \mid \dots \mid 9)^*$

正则定义的例子2

无符号数的正则表达式, 例如: 1946, 11.28, 63.6E8, 1.99E-6

digit $\rightarrow 0 \mid 1 \mid \dots \mid 9$

digits $\rightarrow digit\ digit^*$

optionalFraction $\rightarrow .digits \mid \epsilon$

optionalExponent $\rightarrow (E\ (+\mid-\mid\epsilon)\ digits) \mid \epsilon$

number $\rightarrow digits\ optionalFraction\ optionalExponent$

正则表达式的扩展

1. “+”：一个或多个，表示一个正则表达式及其语言的正闭包， r^+ 表示语言 $(L(r))^+$

$$r^* = r^+ \mid \varepsilon$$

$$r^+ = r r^*$$

2. “?”：零个或一个出现，也就是说， $r?$ 等价于 $r \mid \varepsilon$

3. “[]”：一个正则表达式 $a_1 \mid a_2 \mid \dots \mid a_n$ （其中 a_i 是字母表中的各个符号）可以缩写成

$[a_1 a_2 \dots a_n]$ 。

例如： $[ade] = a \mid d \mid e$

[范围]：如果 $a_1 \mid a_2 \mid \dots \mid a_n$ 是连续字符集、数字集等，

例如： $[A-Z] = A \mid B \mid C \mid \dots \mid Z$

正则表达式的扩展

1. “+”：一个或多个，表示一个正则表达式及其语言的正闭包， r^+ 表示语言 $(L(r))^+$

$$r^* = r^+ \mid \varepsilon$$

$$r^+ = r r^*$$

2. “?”：零个或一个出现，也就是说， $r?$ 等价于 $r \mid \varepsilon$

3. “[]”：一个正则表达式 $a_1 \mid a_2 \mid \dots \mid a_n$ （其中 a_i 是字母表中的各个符号）可以缩写成

$[a_1 a_2 \dots a_n]$ 。

例如： $[ade] = a \mid d \mid e$

[范围]：如果 $a_1 \mid a_2 \mid \dots \mid a_n$ 是连续字符集、数字集等，

例如： $[A-Z] = A \mid B \mid C \mid \dots \mid Z$

使用简化的表达方式

- C语言的标识符集合

$letter \rightarrow A \mid B \mid \dots \mid Z \mid a \mid b \mid \dots \mid z \mid _$

$digit \rightarrow 0 \mid 1 \mid \dots \mid 9$

$id \rightarrow letter (letter \mid digit)^*$

- 简化为：

$letter \rightarrow [A-Za-z_]$

$digit \rightarrow [0-9]$

$id \rightarrow letter (letter \mid digit)^*$

则C语言标识符的正则表达式： $[A-Za-z_]([A-Za-z_] \mid [0-9])^*$

无符号数的正则表达式

$digit \rightarrow [0-9]$

$digits \rightarrow digit^+$

$number \rightarrow digits (.digits)? (E(+|-)? digits)?$

则无符号数的正则表达式为: $[0-9]^+ ([0-9]^+)? (E(+|-)? [0-9]^+)?$

给出 $\Sigma=\{0, 1\}$ 上的正则表达式

① 仅含有两个1，任意个0

$0^*10^*10^*$

② 不包含连续的0

$(1 \mid 01)^*(\varepsilon \mid 0)$

③ 包含偶数个0

$(1^*01^*01^*)^*1^*$

请思考下列问题：

假设给定写出如下正则表达式，如果要写出识别某字符串是否符合该正则表达式，请思考如何用编程语言来实现！

- ① C语言标识符的正则表达式： $[A-Za-z_]([A-Za-z_] | [0-9])^*$
- ② 无符号数的正则表达式为： $[0-9]^+ (.[0-9]^+)? (E(+|-)? [0-9]^+)?$

写出能正确分析识别字符串是否满足词法规则的分析程序是比较困难的？

采用什么方法可以降低设计这样程序的难度呢？

有限状态自动机

正则表达式的练习题

习题1： 写出正则表达式： 匹配所有以字母开头，后跟任意个数字或字母的字符串。

习题2： 写出正则表达式： 匹配所有由连续的 0 和 1 组成的字符串。

习题3： 写出正则表达式： 匹配所有**仅由偶数个 1** 组成的字符串。

习题4： 写出正则表达式： 匹配所有**仅由奇数个 1** 组成的字符串。

习题5： 写出正则表达式： 匹配所有由 a、b、c 三个字符组成的字符串，且每个字符至少出现一次。

习题6： 正则表达式： 匹配所有由至少一个数字和一个字母组成的字符串。

有限状态自动机 (Finite Automaton, FA)

- 有限状态自动机是编译原理中词法分析的理论基础。
- 编译器需要快速、准确地识别源程序中的词法单元，而FA提供了一种形式化模型来描述和实现这种识别过程。
- 与正则表达式相比，FA更贴近实际的程序实现，通常将正则表达式转换为等价的FA，再据此生成词法分析器的驱动代码。


有限状态自动机分类

- FA由有限个状态和状态之间的转换构成，根据转移函数的不同，可分为：
 - ① 确定有限状态自动机（DFA）：每个状态对每个输入符号至多有一个转移，无 ε （空串）转移
 - ② 非确定有限状态自动机（NFA）：每个状态对每个符号可有零个或多个转移，可包含 ε 转移


状态转换图

- 是一个有向图，**结点表示状态**，用**圆圈表示**；
- 用**双圆圈表示识别结束**；
- 用**带*的双圆圈**表示识别结束，**并且需要回退1个字符**；
- 结点之间可以用**有向边连接**；
- 有向边上标记影响状态改变的**可能输入的字符**；

关系算符的转换图




标识符和保留字的转换图



installId() 是一个函数，将识别的标识符插入符号表

无符号数的转换图

$\text{number} \rightarrow \text{digit}^+ (. \text{digit}^+)? (E (+ | -)? \text{digit}^+)?$




`return( number() )`

空格或空白行识别的转换图

delim $\rightarrow$ **blank** | **tab** | **newline**

ws $\rightarrow$ **delim**⁺




不确定的有限自动机（简称NFA）

NFA是一个数学模型，它包括：

- 1、有限状态集合 S
- 2、输入非空字母符号的集合 Σ
- 3、转换函数 $f: S \times (\Sigma \cup \{\varepsilon\}) \rightarrow S$
- 4、状态 s_0 是开始状态
- 5、 $F \subseteq S$ 是接受状态集合

假设识别语言


$(a|b)^*ab$ 的NFA




• NFA的转换表

状 态	输 入 符 号	
	<i>a</i>	<i>b</i>
0	{0, 1}	{0}
1	∅	{2}
2	∅	∅

识别语言
 $(a|b)^*ab$ 的NFA




- 例: 识别 $aa^*|bb^*$ 的NFA



确定的有限自动机（简称DFA）

- 1、状态集合 S
- 2、输入符号集合 Σ
- 3、转换函数 $D : S \times \Sigma \rightarrow S$
- 4、唯一的初始状态 s_0
- 5、对于每个状态 s 和每个输入符号 a ，只有唯一标有 a 的边离开
- 6、 $F \subseteq S$ 是接受状态集合

识别语言
 $(a|b)^*ab$ 的DFA



NFA到DFA的等价变换

- 词法分析要扫描大量源代码，每一毫秒的性能都直接关系到编译器整体速度。
虽然 NFA 与 DFA 在表达能力上等价，但在运行时的行为上却有本质差别。
- NFA 的非确定性带来的多重路径NFA 的“非确定性”；
- 意味着 同一个状态、同一个输入字符，可能转移到多个不同的下一个状态；
- 还可以通过 ϵ 转移在不消耗任何输入字符的情况下改变状态。这让直接模拟 NFA 的运行变得复杂。
- 介绍一种称为子集法的算法实现NFA→DFA的转换


为什么要先构造 NFA 再转换，而不是直接构造 DFA？

- 从正则表达式直接构造 DFA 比较困难；
- 而 NFA 的构造却非常直接（比如 Thompson 构造法），可以机械地把正则表达式拆分成图结构。
- 再通过子集构造法（Subset Construction）把 NFA 转成等价的 DFA。
- 标准流程是：正则表达式 → NFA → DFA → 最小化 DFA → 词法分析器代码

NFA转换到DFA的相关运算

- ① 状态集 I 的 ϵ -闭包，表示为 $\epsilon\text{-closure}(I)$ ，是指从 I 中任意状态出发，通过空转移（ ϵ -转移）可以到达的所有状态的集合。计算 ϵ -闭包的算法通常使用深度优先搜索（DFS）来实现。
- ② 状态集 I 的 a 弧转移，表示为 $\text{move}(I,a)$ ，记为状态集 J ，则 J 表示从 I 中的某一状态经过一条 a 弧所到达的状态集。

NFA到DFA的变换



(1) $\epsilon\text{-closure}(\{0\}) = \{0, 1, 2, 4, 7\}$

即 $\{0, 1, 2, 4, 7\}$ 中的任一状态都是从状态0经任意条 ϵ 弧可到达的状态

(2) 令 $\{0, 1, 2, 4, 7\} = A$, 则 $\text{move}(A, a) = \{3, 8\}$

(3) $\epsilon\text{-closure}(\{3, 8\}) = \{1, 2, 3, 4, 6, 7, 8\}$

构造NFA的状态子集的算法

假定所构造的子集族为 T ，即 $T=\{T_1, T_2, \dots, T_i\}$ 其中 $T_1, T_2, \dots, T_i$ 为状态 S 的子集。

① 开始，令 $\epsilon\text{-closure}(s_0)$ 为 T 中唯一成员，并且它是未被标记的。

② While(T 中有未被标记的子集 T_i)do

{标记 T_i ;

for 每个输入字母 a do


{ $U = \epsilon\text{-closure}(\text{Move}(T_i, a))$;

if U 不在 T 中 then

将 U 做为未被标记的子集加在 T 中

}

}



$T0 = \{0, 1, 2, 4, 7\}$

$T1 = \{1, 2, 3, 4, 6, 7, 8\}$

$T2 = \{1, 2, 4, 5, 6, 7\}$

$T3 = \{1, 2, 4, 5, 6, 7, 9\}$

$T = \{\}$ $T = \{T0\}$ $T = \{T0, T1\}$

$T = \{T0, T1, T2\}$ $T = \{T0, T1, T2, T3\}$


1. 计算 $\epsilon\text{-closure}(\{0\}) = \{0, 1, 2, 4, 7\} = T0$, 没有在集合T中, 加入集合T中

2. 计算 $\text{Move}(T0, a) = \{3, 8\}$; $\epsilon\text{-closure}(\text{Move}(T0, a)) = \{1, 2, 3, 4, 6, 7, 8\} = T1$, 加入集合T中;

3. 计算 $\text{Move}(T0, b) = \{5\}$; $\epsilon\text{-closure}(\text{Move}(T0, b)) = \{1, 2, 4, 5, 6, 7\} = T2$, 加入集合T中;

4. 计算 $\text{Move}(T1, a) = \{3, 8\}$; $\epsilon\text{-closure}(\text{Move}(T1, a)) = \{1, 2, 3, 4, 6, 7, 8\} = T1$, 已在集合T中;

5. 计算 $\text{Move}(T1, b) = \{5, 9\}$; $\epsilon\text{-closure}(\text{Move}(T1, b)) = \{1, 2, 4, 5, 6, 7, 9\} = T3$, 加入集合T中。



$T0=\{0,1,2,4,7\}$

$T1=\{1,2,3,4,6,7,8\}$

$T2=\{1,2,4,5,6,7\}$

$T3=\{1,2,4,5,6,7,9\}$

$T4=\{1,2,4,5,6,7,10\}$

$T=\{T0,T1,T2,T3\}$

$T=\{T0,T1,T2,T3,T4\}$

6. 计算 $\text{Move}(T2,a)=\{3,8\}$; $\epsilon\text{-closure}(\text{Move}(T2,a))=\{1,2,3,4,6,7,8\}=T_1$, 已在集合T中;

7. 计算 $\text{Move}(T2,b)=\{5\}$; $\epsilon\text{-closure}(\text{Move}(T2,b))=\{1,2,4,5,6,7\}=T_2$, 已在集合T中;

8. 计算 $\text{Move}(T3,a)=\{3,8\}$; $\epsilon\text{-closure}(\text{Move}(T3,a))=\{1,2,3,4,6,7,8\}=T_1$, 已在集合T中;

9. 计算 $\text{Move}(T3,b)=\{5,10\}$; $\epsilon\text{-closure}(\text{Move}(T3,b))=\{1,2,4,5,6,7,10\}=T_4$, 加入集合T中;

10. 计算 $\text{Move}(T4,a)=\{3,8\}$; $\epsilon\text{-closure}(\text{Move}(T4,a))=\{1,2,3,4,6,7,8\}=T_1$, 已在集合T中

11. 计算 $\text{Move}(T4,b)=\{5,8\}$; $\epsilon\text{-closure}(\text{Move}(T4,b))=\{1,2,4,5,6,7\}=T_2$, 已在集合T中;

将上述过程总结为：

1. 计算 ϵ -closure($\{0\}$) = $\{0, 1, 2, 4, 7\} = T_0$
2. 计算 ϵ -closure(Move(T_0, a)) = $\{1, 2, 3, 4, 6, 7, 8\} = T_1$
3. 计算 ϵ -closure(Move(T_0, b)) = $\{1, 2, 4, 5, 6, 7\} = T_2$
4. 计算 ϵ -closure(Move(T_1, a)) = $\{1, 2, 3, 4, 6, 7, 8\} = T_1$
5. 计算 ϵ -closure(Move(T_1, b)) = $\{1, 2, 4, 5, 6, 7, 9\} = T_3$
6. 计算 ϵ -closure(Move(T_2, a)) = $\{1, 2, 3, 4, 6, 7, 8\} = T_1$
7. 计算 ϵ -closure(Move(T_2, b)) = $\{1, 2, 4, 5, 6, 7\} = T_2$
8. 计算 ϵ -closure(Move(T_3, a)) = $\{1, 2, 3, 4, 6, 7, 8\} = T_1$
9. 计算 ϵ -closure(Move(T_3, b)) = $\{1, 2, 4, 5, 6, 7, 10\} = T_4$
10. 计算 ϵ -closure(Move(T_4, a)) = $\{1, 2, 3, 4, 6, 7, 8\} = T_1$
11. 计算 ϵ -closure(Move(T_4, b)) = $\{1, 2, 4, 5, 6, 7\} = T_2$

那么NFA N构造的DFA M为：

1. $S = \{T_0, T_1, T_2, T_3, T_4\}$

2. $\Sigma = \{a, b\}$

$D(T_0, a) = T_1$ $D(T_0, b) = T_2$

$D(T_1, a) = T_1$ $D(T_1, b) = T_3$

$D(T_2, a) = T_1$ $D(T_2, b) = T_2$

$D(T_3, a) = T_1$ $D(T_3, b) = T_4$

$D(T_4, a) = T_1$ $D(T_4, b) = T_2$

4. $S_0 = T_0$

5. $S_f = T_4$

包含原NFA
终态的T4加
到终态集合

将T0,T1,T2,T3,T4重新命名为A,B,C,D,E状态转换图变为

$D(T0,a)=T1$ $D(T0,b)=T2$

$D(T1,a)=T1$ $D(T1,b)=T3$

$D(T2,a)=T1$ $D(T2,b)=T2$

$D(T3,a)=T1$ $D(T3,b)=T4$

$D(T4,a)=T1$ $D(T4,b)=T2$



$D(A,a)=B$

$D(A,b)=C$

$D(B,a)=B$

$D(B,b)=D$

$D(C,a)=B$

$D(C,b)=C$


$D(D,a)=B$

$D(D,b)=E$

$D(E,a)=B$

$D(E,b)=C$

NFA状态集	DFA状态	输入符号	
		<i>a</i>	<i>b</i>
$\{0,1,2,4,7\}$	<i>A</i>	<i>B</i>	<i>C</i>
$\{1,2,3,4,6,7,8\}$	<i>B</i>	<i>B</i>	<i>D</i>
$\{1,2,4,5,6,7\}$	<i>C</i>	<i>B</i>	<i>C</i>
$\{1,2,4,5,6,7,9\}$	<i>D</i>	<i>B</i>	<i>E</i>
$\{1,2,4,5,6,7,10\}$	<i>E</i>	<i>B</i>	<i>C</i>



确定有限自动机（DFA）最小化

- 确定有限自动机（DFA）最小化是指将一个给定的DFA转换为等价的具有最少状态数的DFA的过程。
- 最小化DFA的主要目的是简化自动机的结构，减少状态数，提高匹配效率。


DFA最小化---Hopcroft算法

- Hopcroft算法是一种经典的确定有限自动机（DFA）最小化算法，它基于等价状态划分法，能够高效地将一个给定的 DFA 转换为具有最少状态数的等价 DFA。
- 对于每一对不同的状态 (p,q) ，如果 (p,q) 在任意输入符号下转移到相同的状态属于相同等价类，则将 (p,q) 划分到相同类中；如果 (p,q) 在任意输入符号下转移到的状态分别属于不同的等价类，则将 (p,q) 划分到不同的等价类中。

Hopcroft算法的详细描述

- ✓ 步骤1：将 DFA 的状态划分为两类：接受状态和非接受状态。将接受状态和非接受状态分别构成两个初始等价类。
- ✓ 步骤2：重复以下步骤，直到不能再细分为止：
 - ① 对于每一对不同的状态 (p,q) ，以及 DFA 的每个输入符号 a ：计算状态 p 和 q 经过输入符号 a 转移到的状态分别为 r 和 s 。
 - ② 如果 r 和 s 不属于同一等价类，则将 (p,q) 划分到不同的等价类中。
 - ③ 检查是否有状态发生了划分，如果有则更新等价类划分，继续下一轮迭代。
- ✓ 步骤3：对分划完成后的每个状态子集，合并为一个状态，同时合并状态转移。

Hopcroft算法示例



第1步：将自动机的状态划分两个子集形成等价划分：


$G1=\{A,B,C,D\}$, $G2=\{E\}$

第2步：由于G2只有E，不可能再分；考察G1的每个状态ABCD,输入字符a, 都转移到子集G1；输入字符b, 状态ABC转移到G1, D转移到G2, 此时, G1划分为子集 $G3=\{A,B,C\}$, $G4=\{D\}$;

第3步：由于G4只有D, 不可能再分；考察G3的每个状态ABC,输入字符a, 都转移到子集G3；输入字符b, 状态AC转移到G3, B转移到G4, 此时, G3划分为子集 $G5=\{A,C\}$, $G6=\{B\}$;

第4步：由于G6只有B, 不可能再分；考察G5的每个状态AC,输入字符a, 都转移到子集G6；输入字符b, 都转移到G5, 因此, 停止划分。

Hopcroft算法示例（续）




第5步：将自动机的状态划分四个子集：

$G4=\{D\}$, $G5=\{A,C\}$, $G6=\{B\}$, $G2=\{E\}$;

第6步：将状态集重新命名：

$s0=\{A,C\}$, $s1=\{B\}$, $s2=\{D\}$, $s3=\{E\}$;

重新画出状态转换图如下：




正则表达式与有限状态自动机的关系

- 正则表达式的特点：
 - ① 正则表达式提供了丰富的语法和操作符，可以描述各种复杂的模式；
 - ② 用较短的表达式就能描述复杂的匹配规则，简化了模式匹配的过程；
 - ③ 适用于多种编程语言和工具，是一种通用的字符串匹配工具。
- 有限状态自动机的特点：
 - ① 确定有限自动机在处理字符串匹配时具有确定性，不会出现歧义。
 - ② 提供了一种形式化的方式来描述和处理字符串匹配问题，直观易懂，便于理论分析和算法设计。
- 在字符串识别正则表达式与有限状态自动机是等价的


从正则式到NFA转换---Thompson构造算法

规则1: 对于每个字符（包括字母、数字、运算符等），构建一个基本的NFA。

这个基本的NFA 包含两个状态，一个起始状态和一个接受状态，中间有一条转移边，标记为该字符。




识别正则式 ϵ 的NFA



识别正则式 a 的NFA

从正则式到NFA


规则2: 对于正则表达式 st ，其中 s 和 t 是正则表达式，构建两个NFA，然后通过 ε 边将第一个NFA 的接受状态连接到第二个NFA 的起始状态。



识别正规式 st 的NFA

从正则式到NFA


规则3：对于正则表达式 $s \mid t$ ，构建两个NFA，然后添加新的起始状态，并通过 ϵ 边将新的起始状态连接到两个NFA的起始状态。



识别正规式 $s \mid t$ 的NFA

从正则式到NFA

规则4： 对于正则表达式 s^* ，构建一个NFA，然后添加新的起始状态和接受状态，并通过 ε 边将新的起始状态连接到原始NFA的起始状态和接受状态，以及从原始NFA的接受状态到新的起始状态。



识别正则式 s^* 的NFA


该方法产生的NFA有下列性质:

- ① $N(r)$ 的状态数最多是 r 中符号和算符总数的两倍
- ② $N(r)$ 只有一个开始状态和一个接受状态，接受状态没有向外的转换
- ③ $N(r)$ 的每个状态有一个用 Σ 的符号标记的指向其它结点的转换，或者最多两个指向其它结点的 ϵ 转换


从正则式到NFA的示例

例如：将正则表达式 $(a|b)^*abb$ 转换为NFA

(1) 根据规则1，为字符a和b分别构造NFA




识别正则式 a 的NFA



识别正则式 b 的NFA


从正则式到NFA的示例

(2) 根据规则3，构造正则表达式 $a|b$ 的NFA




从正则式到NFA的示例

(4) 根据规则4，构造正则表达式 $(a|b)^*$ 的NFA



从正则式到NFA的示例


(5) 根据规则1, 为字符a构造NFA



识别正则式 a 的NFA


从正则式到NFA的示例

(6) 根据规则2, 构造 $(a|b)^*a$ 的NFA




从正则式到NFA的示例

(7) 根据规则2, 构造 $(a|b)^*ab$ 的NFA



从正则式到NFA的示例

(8) 根据规则2, 构造 $(a|b)^*abb$ 的NFA



由正则式转换成NFA---另外一种构造法


正则式

转换系统


$\emptyset$




ε



a_i




e




正则式

转换系统


$e_1 \mid e_2$







$e_1 e_2$







e^*



由正则式转换成NFA示例 $(a|b)^*(aa|bb)(a|b)^*$





将正则式 $(a|b)^*abb$ 转换成NFA示例



构造词法分析器的一般步骤

- ① 用正规式对程序设计语言单词模式进行描述；
- ② 使用Thompson构造法，根据正则表达式构建对应的NFA。
- ③ 使用子集构造法（subset construction）将NFA转换为DFA；
- ④ 简化DFA，使其状态数最少；
- ⑤ 从化简后的DFA构造词法分析程序。

将NFA转换为DFA



$$\epsilon\text{-closure}(0)=\{0,1,2\}=A$$

$$\epsilon\text{-closure}(\text{move}(A,a))=\{1,2,3\}=B$$

$$\epsilon\text{-closure}(\text{move}(A,b))=\{1,2\}=C$$

$$\epsilon\text{-closure}(\text{move}(B,a))=\{1,2,3\}=B$$

$$\epsilon\text{-closure}(\text{move}(B,b))=\{1,2,4\}=D$$

$$\epsilon\text{-closure}(\text{move}(C,a))=\{1,2,3\}=B$$

$$\epsilon\text{-closure}(\text{move}(C,b))=\{1,2\}=C$$


$$\epsilon\text{-closure}(\text{move}(D,a))=\{1,2,3\}=B$$

$$\epsilon\text{-closure}(\text{move}(D,b))=\{1,2,F\}=E$$

$$\epsilon\text{-closure}(\text{move}(E,a))=\{1,2,3\}=B$$

$$\epsilon\text{-closure}(\text{move}(E,b))=\{1,2\}=C$$

化简DFA



DFA状态	输入符号	
	<i>a</i>	<i>b</i>
S_0	S_1	S_0
S_1	S_1	S_2
S_2	S_1	S_3
S_3	S_1	S_0



词法分析器实现的方式

➤ 实际编译器中的词法分析器可以使用两种方式实现：

① 表驱动将 DFA 表示成一张二维表：行是状态，列是输入符号，单元格存放下一状态编号。

驱动程序只需维护一个当前状态变量，不断读入字符并查表更新。此外还需要一张状态表标明哪些状态是接受状态以及对应的词法单元编号。该方式的优点是逻辑简单、易于自动生成。

② 直接编码：将 DFA 的状态转移逻辑直接写成程序代码，例如：使用switch 或 if-else。每个状态对应一段代码，根据输入的字符分支跳转。这种方式没有查表开销，灵活性高，但维护困难，通常由工具生成。比如：flex词法分析生成工具。

➤ 词法分析器在做实际匹配时还常利用最长匹配和向前看。

例如：识别 $\leq$ 时，识别完 $<$ 后不能立即输出，要继续读取下一个字符，若 $=$ 则认为是 $\leq$ ，否则需要回退字符位置到只读入 $<$ 的状态。这要求词法分析器能够在匹配不成功时“回退”，在实现中可以保存上次接受状态的位置。

使用词法分析器生成工具

➤ 通过编写词法规则描述文件，使用工具自动生成词法分析器的代码。常见的词法分析器生成工具有：

- ① Lex / Flex：用于生成C语言的词法分析器
- ② JLex / JFlex：用于生成Java语言的词法分析器
- ③ ANTLR：支持多种编程语言的词法分析器生成

下面将给出直接编码编写词法分析的示例：

(a|b)*abb等价的DFA如下：

DFA状态	输入符号	
	<i>a</i>	<i>b</i>
S_0	S_1	S_0
S_1	S_1	S_2
S_2	S_1	S_3
S_3	S_1	S_0

- 可以根据DFA设计词法分析程序，右边是对应的简易的词法分析程序，从输入的字符串中识别出符合 (a|b)*abb模式的词法单元；
- 程序核心部分采用while循环和switch分支处理识别符合正则表达式的词法单元，switch的case分支对应DFA的状态，DFA的状态变化在程序中用state来记录。

```
1  #include <stdio.h>
2  #include <string.h>
3  int main()
4  {
5      char input[100];
6      int state = 0;
7      int i = 0;
8      int start_index = 0;
9      int j = 0;
10     printf("Enter input string: ");
11     gets(input);
12     while (input[i] != '\0')
13     {
14         switch (state)
15         {
16             case 0:
17                 if (input[i] == 'a')
18                 {
19                     state = 1;
20                 }
21                 else if (input[i] == 'b')
22                 {
23                     state = 0;
24                 }
25             else
26             {
27                 state = -1; /* Invalid input*/
28             }
29             break;
```

(a|b)*abb正则表达式的模式串识别

DFA状态	输入符号	
	<i>a</i>	<i>b</i>
<i>S</i> ₀	<i>S</i> ₁	<i>S</i> ₀
<i>S</i> ₁	<i>S</i> ₁	<i>S</i> ₂
<i>S</i> ₂	<i>S</i> ₁	<i>S</i> ₃
<i>S</i> ₃	<i>S</i> ₁	<i>S</i> ₀

- 右边程序片段是完成状态1和状态2的处理
- state=-1表明输入的正则表达式不能识别的字符，此处可以是一些错误处理代码。


```
30 case 1:
31     if (input[i] == 'a')
32     {
33         state = 1;
34     }
35     else if (input[i] == 'b')
36     {
37         state = 2;
38     }
39     else
40     {
41         state = -1; /* Invalid input*/
42     }
43     break;
44 case 2:
45     if (input[i] == 'a')
46     {
47         state = 1;
48     }
49     else if (input[i] == 'b')
50     {
51         state = 3;
52     }
53     else
54     {
55         state = -1; /*Invalid input*/
56     }
57     break;
```

```
58 case 3:
59     if (input[i] == 'a')
60     {
61         state = 1;
62     }
63     else if (input[i] == 'b')
64     {
65         state = 0;
66     }
67     else if (input[i] == ' ')
68     {
69         for (j = start_index; j <= i; j++)
70         {
71             printf("%c", input[j]);
72         }
73         printf("\n");
74     }
75     else
76     {
77         state = -1; /*Invalid input*/
78     }
79     break;
80 default:
81     break;
82 }
83 if (input[i] == ' ')
84 {
85     state = 0;
86     start_index = i + 1;
87 }
88 i++;
89 }
```

本示例假定空格作为词法单元（单词）的分隔符，如果state=3且当前字符为空格时，此时已经识别了一个符合正则表达式的词法单元，使用循环语句打印输出，否则丢弃该单词，进行下一个单词的识别。

```
90
91     if (state == 3)
92     {
93         for (j = start_index; j <= i; j++)
94         {
95             printf("%c", input[j]);
96         }
97         printf("\n");
98     }
99
100     return 0;
101 }
```

DFA 状态	输入符号	
	<i>a</i>	<i>b</i>
S_0	S_1	S_0
S_1	S_1	S_2
S_2	S_1	S_3
S_3	S_1	S_0



一个简易词法分析器的实现（1）

```
#include <stdio.h>
#include <ctype.h>
#include <stdbool.h>
#include <string.h>
```

// 状态枚举

```
typedef enum {
    START,
    IN_COMMENT,
    IN_NUM,
    IN_ID,
    IN_ASSIGN,
    IN_SLASH,
    IN_STRING,
    DONE
} Token;
```

```
// 判断是否为字母或下划线
bool isAlphaOrUnderscore(char c) {
    return isalpha(c) || c == '_';
}
```

// 词法分析器

```
void lexer(const char *code) {
    Token token = START;
    char currentChar;
    int pos = 0;
    while (token != DONE) {
        currentChar = code[pos++];
```

```
switch (token) {
    case START:
        if (currentChar == '/') {
            token = IN_SLASH;
        } else if (isdigit(currentChar)) {
            token = IN_NUM;
            printf("NUM: %c", currentChar);
        } else if (isAlphaOrUnderscore(currentChar)) {
            token = IN_ID;
            printf("ID: %c", currentChar);
        } else if (currentChar == '=') {
            token = IN_ASSIGN;
            printf("ASSIGN: %c", currentChar);
        } else if (currentChar == '"') {
            token = IN_STRING;
            printf("STRING: ");
        } else if (currentChar == '\0') token = DONE;
        break;
```

一个简易词法分析器的实现（2）

case IN_SLASH:

```
if (currentChar == '*') {  
    token = IN_COMMENT;  
} else {  
    printf("DIVIDE: \n");  
    token = START;  
    pos--; // 回退一个字符  
}  
break;
```

case IN_COMMENT:

```
if (currentChar == '*' && code[pos] == '/') {  
    token = START;  
    pos++; // 跳过 '/'  
} else if (currentChar == '\0') {  
    token = DONE;  
}  
break;
```

case IN_NUM:

```
if (isdigit(currentChar)) {  
    printf("%c", currentChar);  
} else {  
    token = START;  
    printf("\n");  
    pos--; // 回退一个字符  
}  
break;
```

case IN_ID:

```
if (isAlphaOrUnderscore(currentChar) ||  
    isdigit(currentChar)) {  
    printf("%c", currentChar);  
} else {  
    token = START;  
    printf("\n");  
    pos--; // 回退一个字符  
} break;
```

一个简易词法分析器的实现（3）

case IN_ASSIGN:

```
if (currentChar == '=') {  
    printf("%c\n", currentChar);  
} else {  
    printf("\n");  
    pos--; // 回退一个字符  
}  
token = START;  
break;
```

case IN_STRING:

```
if (currentChar == '"') {  
    printf("\n");  
    token = START;  
} else if (currentChar == '\0') {  
    token = DONE;  
} else {  
    printf("%c", currentChar);  
}  
break;  
default:  
break;  
}  
}  
}
```

一个简易词法分析器的实现（3）

```
int main() {  
    const char *code = "int a = 42;\n/* This is a comment *\nb = a + 2;\nchar *str = \"Hello, World!\";\n";  
    lexer(code);  
    return 0;  
}
```

词法分析器可以识别数字、标识符、赋值符号、除法符号、字符串和多行注释。
请注意，这个实现仍然相对简单，仅用于演示目的。实际的C语言词法分析器会更加复杂，需要处理更多的状态和符号。

运行输出的结果

ID: int

ID: a

ASSIGN: =

NUM: 42

ID: b

ASSIGN: =

ID: a

NUM: 2

ID: char

ID: str

ASSIGN: =

STRING: Hello, World!

```
ID: int  
ID: a  
ASSIGN: =  
NUM: 42  
ID: b  
ASSIGN: =  
ID: a  
NUM: 2  
ID: char  
ID: str  
ASSIGN: =  
STRING: Hello, World!
```

有限状态自动机在编译技术中承担的角色

- ① 作为正则表达式的执行模型，将“描述语言”转化为“识别语言”的算法；
- ② 通过 DFA 提供线性时间、确定性的词法识别；
- ③ 借助工具（Lex/Flex）从正则表达式自动生成词法分析器代码；关键算法——Thompson 构造、子集构造和 DFA 最小化——构成了从描述到实现的核心流水线。
- ④ 理解这些算法能帮助我们掌握词法分析器的构造原理，也为后续语法分析中的自动机技术（如 LR 自动机）提供了类比基础。

有限状态自动机FA 与正则表达式(RE)的关系及局限性

- 正则表达式与 FA 是同一数学体系的两面：正则表达式定义语言，FA 识别语言。
- 两者之间的转换算法（RE→NFA→DFA→最小化）是编译器自动生成词法分析器的基础。但 FA 作为一种状态数有限的模型，不能识别非正则语言。例如：
 - ① 配对的括号语言（需无限计数）；
 - ② $a^n b^n$ （需要比较前后数量）；
 - ③ 嵌套的结构。因此在编译器中，词法分析用的 FA 只处理单词的结构，而句子级嵌套规则由语法分析（如下推自动机、LR 分析器）处理。

词法分析相关的作业

- ① 请写出一个正则表达式，匹配所有由 0 和 1 组成的偶数个字符的字符串。
- ② 给定正则表达式 $(a|b)(aa|bb)^*(a|b)$ ，请画出对应的非确定有限自动机（NFA），并转换为确定有限自动机（DFA），并最小化DFA；请编程实现从字符串中提取符合该正则表达式的C语言程序。
- ③ 给定一个确定有限自动机（DFA），如何将其转换为等价的正则表达式？
- ④ 给定一个确定有限自动机（DFA），如何判断它是否已经是最小化的状态？